

Metodos de la Investigación Social



Clase 06

A ver hoy


Medición en Ciencias Sociales

- Medición en Ciencias Sociales
- Estándares de Medición



Hoy vamos a discutir como la producción de datos se relaciona con el concepto de medición en ciencias sociales.

Dos tradiciones



Medición como herramienta

La medición al servicio de propósitos sociales

En su libro *Notas sobre la medición social* (1984, p. 2), Duncan indica:



Lo que estoy tratando de sugerir es que muchos—y quizás los mas básicos—de los procedimientos que usan los científicos naturales y sociales en la medición fueron de hecho inventados para resolver problemas prácticos.

En un comienzo, la medición servía solamente propósitos sociales.

[El/la] científico puede aparecer en la foto cuando hay una necesidad reconocida de mejorar el instrumento de medición. O, tomando la práctica actual de medición como un punto de partida, [el/ella] puede dejar su imaginación trabajar libremente sobre las ideas de cantidad, extensión, magnitud, intensidad, duración, numerosidad, dimensión, escala y proporción para crear estructuras conceptuales abstractas y sistemas de relaciones.

Duncan (1984)



Duncan, O. D. (1984). *Notes on social measurement: Historical and critical*. Russell Sage Foundation.

En ciencias sociales, y en el público en general, existe la intuición que efectivamente podemos medir.

O cuando menos parecemos operar sobre ese supuesto en múltiples contextos.

Al mismo tiempo, parece razonable considerar que hay casos en los cuáles no hemos logrado (o no es posible) medir atributos que nos interesan.

¿De qué depende que en una situación particular yo pueda afirmar (o no) que puedo medir un atributo?

¿Cuándo podemos decir que logramos medir un atributo que nos interesa?

1. Depende de la calidad del instrumento de medición que se usó para medir el atributo.

1. Depende de la calidad del instrumento de medición que se usó para medir el atributo.

2. Depende de lo que pretendo hacer con los resultados de la medición.

1. Depende de la calidad del instrumento de medición que se usó para medir el atributo.

2. Depende de lo que pretendo hacer con los resultados de la medición.

3. Depende de lo que pretendo medir.

1. Depende de la calidad del instrumento de medición que se usó para medir el atributo.

2. Depende de lo que pretendo hacer con los resultados de la medición.

3. Depende de lo que pretendo medir.

4. Depende de qué se está entendiendo por “medir”.

¿De qué depende que en una situación particular yo pueda afirmar (o no) que puedo medir un atributo?

1. Depende de qué se está entendiendo por “medir”.
2. Depende de lo que pretendo medir.
3. Depende de lo que pretendo hacer con los resultados de la medición.
4. Depende de la calidad del instrumento de medición que se usó para medir el atributo.

Depende de qué se entiende por “medir”

**¿Qué entendemos por medición en
ciencias sociales?**

Lo qué entendemos por medición delimita:

- a) qué puede y qué no puede ser medido.
- b) si hay “tipos” de medición.
- c) si esos tipos de medición son equivalentes.
- d) qué se entiende por calidad en una medición.

Medición en ciencias sociales

Definiciones en la tradición representacional de Stevens

En general en ciencias sociales se utiliza—para bien o para mal—la definición de Stevens (1946) como punto de partida:

Podemos decir que medición, en el sentido más amplio, es definida como la asignación de numerales a objetos o eventos de acuerdo a reglas.

Stevens (1946)

Y una versión mas elaborada en la misma tradición:

Un procedimiento para la asignación de números (puntajes, mediciones) a propiedades especificadas de unidades experimentales de tal forma que se caracterice y preserven relaciones especificadas en el dominio conductual.

Lord y Novick (1968)

Stevens, S. S. (1946). On the Theory of Scales of Measurement. *Science*, 103(2684).

Lord, F.M., & Novick, M. R. (1968). Statistical theories of mental test scores. Reading, Mass: Addison-Wesley Pub. Co.

¿Qué es una escala?

Varios usos distintos de una misma palabra

“Medimos temperatura usando la escala Celsius”

“Medimos utilizando la escala de autoestima de Rosenberg”

“Medimos utilizando una escala Likert de siete puntos”

“Medimos utilizando una escala intervalar”

¿Qué es una escala?

Varios usos distintos de una misma palabra

“Medimos temperatura usando la escala Celsius”

En este sentido la palabra escala se usa como sinónimo de una unidad de referencia, en base a la cual se interpretan los valores de dicha medición.

“Medimos utilizando la escala de autoestima de Rosenberg”

En este sentido la palabra escala se usa como sinónimo de un conjunto de ítems, presumiblemente un instrumento de medición para un atributo en particular.

“Medimos utilizando una escala Likert de siete puntos”

En este sentido la palabra escala se usa como sinónimo de un formato de respuesta. En este caso particular, se refiere al formato introducido por R. Likert en 1932.

“Medimos utilizando una escala intervalar”

En este sentido la palabra escala se usa como sinónimo del tipo de propiedades matemáticas que se le adscriben a una asignación numérica.

Cuadro 1: Tipos de escalas como las presenta Stevens 1946

Escala	Operacion empirica básica	Estructura del grupo matemático	Estadísticos permisible (invariante)
nominal	Determinacion de igualdad	<i>Grupo permutativo</i> $x' = f(x)$ $f(x)$ significa cualquier substitution “uno esa uno”.	Numero de casos Moda Correlacion contingente
ordinal	Determinacion de más o menos	<i>Grupo isotónico</i> $x' = f(x)$ $f(x)$ significa cualquier funcion monotonicamente creciente.	Mediana Percentiles
intervalar	Determinacion de igualdad de intervalos o diferencias	<i>Grupo lineal general</i> $x' = ax + b$	Media Desviacion estandar Correlacion Producto-momento de Pearson
razón	Determinacion de igualdad de razones	<i>Grupo de similaridad</i> $x' = ax$	Coefficiente de variacion

TIPOS DE PROPIEDADES MATEMÁTICAS DE UNA ESCALA

EJEMPLOS

NOMINAL

Nacionalidad

Número de camiseta en un equipo de fútbol

Número de RUT



Comprende los datos que no tienen un orden; equivalencia.

$=$ $\neq$

ORDINAL

Etapa de desarrollo de un ser vivo

Clase social

Rango académico



Incorpora la relación de “mayor que”

($>$) o “menor que” ($<$)

EJEMPLOS

INTERVALAR (0 arbitrario)

Temperatura

Ubicación en una carretera respecto de un punto de referencia (Kilómetro 85 Ruta 5).


No podemos afirmar que una persona con 100 puntos en un test de inteligencia, es el doble de inteligente que una persona con 50 puntos

DE RAZÓN (0 absoluto, representa ausencia del atributo)

Peso

Sueldo

(en Psicología, no solemos tener escalas de razón)




ESCALAR

Medición en ciencias sociales

Elementos generales del proceso de medición


Más allá de las definiciones particulares de medición que se adopten dentro de la familia de definiciones de “medir es asignar”, podemos entender para efectos de este curso que la medición en ciencias sociales involucra los siguientes elementos:




Medición en ciencias sociales

Asignación y construcción de instrumentos

Veremos que el proceso de asignación, entendido de forma amplia, comprende el diseño, construcción y análisis de instrumentos de medición.



Multiples pasos en el proceso de medición



Depende de lo que pretendo medir.

**¿Qué “cosas” medimos en ciencias
sociales?**

“Attitudes are measured more successfully
than they are defined”

— Allport, 1935

Thesis 1 “Whatever exists at all, exists in some amount”.

Thesis 2. Anything that exists in amount can be measured.

— McCall, 1939

Those data should be measured which can be measured; those which cannot be measured should be treated otherwise.

— Johnson, 1936

Psychological phenomena are neither manipulable nor controllable to the required extent. Therefore they are not measurable.

— Trendler, 2009

Atributos no observables o latentes

Los atributos en las ciencias sociales

NOS INTERESA MEDIR ATRIBUTOS QUE NO PODEMOS OBSERVAR.

En general, las ciencias sociales están interesadas en estudiar y medir atributos que no son observables en el mismo sentido en el que, por ejemplo, distancia es observable.

Atributos como “cohesión social”, “clima escolar”, “ansiedad” y “conocimiento” no son directamente observables y usualmente no podemos manipularlos.

Atributos latentes


Los atributos en las ciencias sociales

El punto clave es que creemos que estos atributos no son observables directamente pero que se manifiestan a través de indicadores visibles.

Un nombre para estos atributos (derivado de la tradición estadística iniciada por Spearman en 1904) es atributos latentes.

Nosotros asumimos la existencia de atributos latentes, y hacemos hipótesis respecto a su estructura.

Hipotetizamos que el atributo latente explica cambios en indicadores observables.



Dado esa hipótesis, hacemos inferencias sobre el atributo latente en base a esos indicadores.

El atributo de interés

¿Qué es lo que queremos medir?

NUESTRO PUNTO DE PARTIDA

El punto de partida de todo proceso de medición es el atributo, en general de tipo latente, que nos interesa medir.

NECESITAMOS INFORMACIÓN SOBRE EL ATRIBUTO LATENTE

Ya que suponemos la existencia del atributo no observable, al diseñar un instrumento de medición queremos saber lo más posible respecto al atributo de interés.

UNA TEORÍA GUÍA NUESTRA SELECCIÓN DE INDICADORES OBSERVABLES

Idealmente, queremos contar con una teoría bien establecida, con soporte empírico documentado, que caracterice cómo este atributo no observable se manifiesta a través de indicadores observables.

El atributo de interés

La estructura como un supuesto a examinar

EL ATRIBUTO GUÍA LAS INFERENCIAS Y EL ANÁLISIS

Nuestra teoría del atributo orienta el tipo de inferencias que tiene sentido hacer, y guía la selección del modelo de análisis de datos para que sea coherente tanto con la teoría como con las inferencias.

El punto clave a destacar es que el análisis y las inferencias se desprendan de esta teoría, y que la estructura que atribuimos al atributo es un aspecto central.

LA ESTRUCTURA DEL ATRIBUTO ES UN SUPUESTO

No hay motivo para suponer a priori que un atributo es necesariamente cuantitativo, ordinal o categórico. Este es un supuesto teórico fundamental que, idealmente, puede ser revisado a la luz de la evidencia.

Las definiciones de nuestros atributos de interés (en conexión con lo que entendemos como medición) definen si creemos que es, en principio, posible el realizar una medición.

La posibilidad de medir un atributo está basada en una definición de ese atributo.

Ahora que sabemos lo importante que es la definición, estamos entonces listos para medir:

“Calidad de la educación”

“Inteligencia”

“Nivel socio-económico”

“Habilidades del siglo XXI”

“Habilidades blandas”

“Desarrollo en primera infancia”

Depende de lo que pretendo hacer con los resultados de la medición.

¿Para que usamos las mediciones en ciencias sociales?

Asumamos que se ha adoptado una
definición de medición y que tenemos una
definición razonablemente clara del
atributo...

Imaginemos que quiero medir la masa de un objeto.

La masa es un atributo que en general se consideraría como “medible” en cualquier definición de medición.

Además contamos con teorías físicas avanzadas que expresan qué es la “masa” de un objeto y que nos sirven para justificar la construcción de un instrumento de medición: una pesa.

Si uso la pesa para medir la masa de un objeto, ¿puedo decir que logré medir el atributo que me interesaba?

Una pesa típica
para masa corporal.



Una pesa típica
para masa corporal.



- La uso para ver si
subí de peso.

Una pesa típica para masa corporal.



- La uso para ver si subí de peso.
- La uso para pesar la dosis de un medicamento

En ambos casos la teoría detrás de la medición, el atributo y el funcionamiento del instrumento es la misma...

Pero no parece razonable el considerar ambos casos como equivalentes.

La calidad de los resultados que produce un instrumento de medición depende de los usos que se les pretende dar.

Un instrumento que puede razonablemente ser utilizado para estudios a nivel poblacional no necesariamente es utilizable para tomar decisiones de altas consecuencias a nivel individual.

Depende de la calidad del instrumento de medición que se usó para medir el atributo.


¿Qué es la calidad de un instrumento de medición en Ciencias Sociales?

En ciencias sociales no hay documentos de consenso que abarquen todas las disciplinas que realizan mediciones en contexto sociales.

Pero sí hay lineamientos expresados por distintos grupos profesionales, y quizá el más influyente en psicometría corresponde a Los Estándares.

¿Qué estándares?

Cautelando la calidad en el uso de pruebas educativas y psicológicas




Tres grandes organizaciones profesionales en Estados Unidos han publicado de forma conjunta desde 1954 un conjunto de normas orientadas a resguardar la calidad de las pruebas en educación y psicología.

La Asociación Psicológica Americana (APA), la Asociación de Investigación Educativa Americana (AERA) y el Consejo Nacional para la Medición Educativa (NCME) publicaron en 2014 la sexta versión de estas normas: los Estándares para el uso de pruebas educativas y psicológicas.

¿Qué estándares?

Cautelando la calidad en el uso de pruebas educativas y psicológicas



Tres grandes organizaciones profesionales en Estados Unidos han publicado de forma conjunta desde 1954 un conjunto de normas orientadas a resguardar la calidad de las pruebas en educación y psicología.

La Asociación Psicológica Americana (APA), la Asociación de Investigación Educativa Americana (AERA) y el Consejo Nacional para la Medición Educativa (NCME) publicaron en 2014 la sexta versión de estas normas: los Estándares para el uso de pruebas educativas y psicológicas.

Tres fundamentos en los estándares

Validez, precisión e imparcialidad

La última versión de los Estándares (2014) incluye tres fundamentos de la medición:

VALIDEZ El grado en que evidencia y teoría respaldan las interpretaciones de puntajes de pruebas para sus usos propuestos.

PRECISIÓN/CONFIABILIDAD La consistencia de los puntajes entre realizaciones de un procedimiento de medición.

IMPARCIALIDAD La capacidad de responder a características individuales y a contextos de aplicación de las pruebas de tal forma que los puntajes de las pruebas produzcan interpretaciones válidas para los usos intencionados.

Validez: un constructo variado y fluido

Definiciones de Validez

Las conceptualizaciones de aquello que es válido han cambiado en el tiempo y es esperable que continúen haciéndolo.

Definición clásica de Validez: “Por validez se entiende el grado en el que una prueba o examinación mide lo que se propone medir” (Ruch, 1924).

Definición actual de Validez: “Validez se refiere al grado en que evidencia y teoría respaldan las interpretaciones de puntajes de pruebas para sus usos propuestos” (AERA, APA & NCME, 2014)

¿Qué pasó entre la definición clásica de Ruch y los Estándares?

Primer fundamento: Validez

De acuerdo a los Estándares para el uso de pruebas educativas y psicológicas

- Validez se refiere al grado en que evidencia y teoría respaldan las interpretaciones de puntajes de pruebas para sus usos propuestos.
- Validez es, por ende, la consideración más fundamental en el desarrollo de pruebas y la evaluación de pruebas... Es la interpretación de los puntajes de las pruebas para los usos propuestos los que son evaluados, no la prueba en sí misma...
- Afirmaciones respecto a la validez deben referirse a interpretaciones particulares para usos específicos. Es incorrecto usar incondicionalmente la frase “la validez de la prueba”.
 - AERA, APA y NCME (2014)


Validez: elementos que la amenazan

De acuerdo a los Estándares para el uso de pruebas educativas y psicológicas



Subrepresentación (o deficiencia) del constructo: “grado con que una prueba ignora (o falla en medir) aspectos relevantes de un constructo”

Varianza irrelevante al constructo o contaminación del constructo: “grado en que los puntajes de una prueba se ven afectados por procesos ajenos a lo que esta pretende medir”



Validez: argumentación a partir de cinco fuentes de evidencia

De acuerdo a los Estándares para el uso de pruebas educativas y psicológicas

Evidencia basada en el contenido de la prueba

Evidencia basada en los procesos de respuesta

Evidencia basada en la estructura interna Evidencia

basada en la relación con otras variables

Evidencia basada en las consecuencias de la prueba

Argumentación de validez a partir de cinco fuentes de evidencia

De acuerdo a los Estándares para el uso de pruebas educativas y psicológicas

Estos cinco tipos de evidencia NO SON TIPOS DISTINTOS DE VALIDEZ.

El proceso de validación de un instrumento se basa en la recolección de estos tipos de evidencia para formar un juicio unificado en relación a la validez de usos o interpretaciones.

Validez: evidencia basada en el contenido

De acuerdo a los Estándares para el uso de pruebas educativas y psicológicas



“Se puede obtener del análisis de las relaciones entre el contenido de la prueba y el constructo que se intenta medir”

[La obtención de] evidencia basada en el contenido puede incluir análisis lógicos o empíricos de la adecuación con que el contenido de una prueba representa el dominio conceptual y de la relevancia del dominio conceptual en la interpretación de los puntajes que se pretende hacer”

aera, apa y ncme (2014)

Ejemplos de evidencia basada en el contenido de la prueba:

- Documentación del proceso de construcción de preguntas y de corrección (por ejemplo: plantillas de preguntas, hipótesis respecto a la dificultad de las preguntas)
- Literatura respecto a la medición del atributo
- Caracterización del atributo de interés
- Revisiones de expertos

Validez: evidencia basada en el contenido

De acuerdo a los Estándares para el uso de pruebas educativas y psicológicas

- ¿Tenemos una definición clara del constructo?
- ¿Qué consideramos una definición clara?
- ¿Podemos interpretar las respuestas de las preguntas como evidencia respecto al constructo?
- ¿Tenemos cobertura de todos los aspectos relevantes del constructo a través de las preguntas?

Validez: evidencia basada en procesos de respuesta

De acuerdo a los Estándares para el uso de pruebas educativas y psicológicas



‘Algunas interpretaciones sobre constructos requieren más o menos explicitación acerca de los procesos cognitivos involucrados al responder una pregunta’

“El análisis del proceso de respuesta de los individuos entrega información respecto del ajuste entre el constructo y la naturaleza particular del desempeño o respuesta ejecutado por los respondentes”

“Esta información puede conducir a reconsiderar el formato de una prueba”

aera, apa y ncme (2014)

Ejemplos de evidencia basada los procesos de respuesta:

- Entrevistas cognitivas, pensamiento en voz alta
- Estudios de Eye-tracking
- Datos de registro en procesos de respuesta
- Tiempos de respuesta

Validez: evidencia basada en procesos de respuesta

De acuerdo a los Estándares para el uso de pruebas educativas y psicológicas

- ¿Están los estudiantes respondiendo por las razones que se espera?
- ¿Qué estrategia están usando los respondentes para resolver un problema?
- ¿Elicita la prueba los procesos cognitivos propios del constructo que se quiere medir?
- ¿Tenemos cobertura de todos los procesos cognitivos relevantes del constructo a través de las preguntas?

Validez: evidencia basada en la estructura interna

De acuerdo a los Estándares para el uso de pruebas educativas y psicológicas



“Un análisis de la estructura interna de una prueba puede indicar el grado en que la relación entre las preguntas de una prueba y sus demás componentes se adecuan al constructo sobre el cual se basan las interpretaciones”

aera, apa y ncme (2014)

Este tipo de evidencia obedece a la pregunta: ¿se comportan las respuestas de la prueba de acuerdo a lo que se espera?

Esto supone la existencia de una teoría a la base del constructo suficientemente clara para poder hacer estas predicciones.

Ejemplos de evidencia basada en la estructura interna:

- Evaluación estadística de las respuestas recogidas en las que se contrastan por una parte los patrones que se esperaba recoger con los patrones que se observan empíricamente.

Validez: evidencia basada en la relación con otras variables

De acuerdo a los Estándares para el uso de pruebas educativas y psicológicas



“El análisis de la relación de los resultados de las pruebas con las variables externas a la prueba proveen otra fuente importante de evidencia de validez”

aera, apa y ncme (2014)

La evidencia basada en la relación con otras variables incluye:

- Evidencia convergente y discriminante (relación positiva con ciertas variables y negativa o inexistente con otras)
- Examinación de relaciones entre la prueba y un criterio externo por medio de diseños concurrentes o predictivos

Validez: evidencia basada en las consecuencias de la evaluación

De acuerdo a los Estándares para el uso de pruebas educativas y psicológicas



“Involucra la recolección de evidencia para evaluar qué tan apropiadas son las interpretaciones propuestas para los usos intencionados.”

aera, apa y ncme (2014)

La evidencia basada en las consecuencias de la evaluación:

- Busca distinguir entre consecuencias relacionadas directamente con la interpretación y el uso de aquellas más indirectas o que podrían ocurrir a más largo plazo
- Incluye la examinación del uso en la práctica de los instrumentos, consecuencias inesperadas y especulación basadas en teorías de la acción.

Segundo fundamento:
Precisión/confiabilidad

Error de medición

El error como un aspecto siempre presente en la medición

Toda medición tiene un cierto nivel de error asociado. Mientras más grande es nuestro error de medición, mayor es nuestra incertidumbre respecto a los resultados de dicha medición.

A menor nivel de error, decimos que nuestra medición es más precisa.

La pregunta no es si una medición tiene o no error, la pregunta es siempre:

¿CUÁN GRANDE ES EL ERROR DE ESTA MEDICIÓN?

o bien

¿QUÉ TAN PRECISA ES ESTA MEDICIÓN?

Error de medición

El error como un aspecto siempre presente en la medición

- ... de la teoría clásica de test:

$$\rightarrow X = T + E$$

↓ ↓ ↓

puntaje observado puntaje verdadero error

→ $\sigma^2 = \sigma^2_{tr} + \sigma^2_e$

↓
varianza verdadera

↓
varianza del error

Varianza de la distribución de los puntajes

- **Confiabilidad:** la proporción de la varianza total que se atribuye a la varianza verdadera

$$\rightarrow r_{xx} = s_{tr}^2 / s^2$$

Error de medición

Aspectos importantes respecto del error de medición

UNA MEDICIÓN ESTÁ INCOMPLETA SIN SU NIVEL DE ERROR ASOCIADO.

No es posible interpretar adecuadamente una medición sin conocer (o tácitamente asumir) el nivel de error asociado a esta.

QUÉ ES UN ERROR GRANDE O PEQUEÑO DEPENDE DEL USO

Si bien en general nos interesa que nuestras mediciones sean lo más precisas posibles, el uso que se le pretende dar a una medición informará nuestras decisiones respecto a lo que es una medición “suficientemente precisa”.

MAYORES CONSECUENCIAS DEMANDAN MAYOR PRECISIÓN

En general, es razonable que mientras mayores sean las consecuencias que se desprenden del uso que se le dará a una medición, mayor es la necesidad de precisión.

Error de medición (en metrología)

Toda medición tiene un grado de incertidumbre asociada

Cuando se reporta el resultado de una medición de una cantidad física, es obligatorio que se entregue alguna indicación cuantitativa de la calidad del resultado para que quienes los usen puedan determinar su confiabilidad.

Sin esta indicación los resultados de medición no pueden ser comparados entre sí, ni con valores de referencia entregados por una especificación o estándar.

*Es, por ende, necesario que exista un procedimiento fácilmente implementable, comprensible y ampliamente aceptado para caracterizar la calidad de un resultado de medición, esto es, para evaluar y expresar su **incertidumbre**.*

Guía para la expresión de la incertidumbre en medición — JCGM (2008)

El error de medición

De acuerdo a los Estándares para el uso de pruebas educativas y psicológicas

El error de medición reduce la utilidad de los puntajes de pruebas.

Limita qué tanto puede generalizarse un resultado mas allá de las características particulares de una aplicación específica de una prueba.

Reduce la confianza que se puede tener en los resultados de una medición y por ende en la confiabilidad/precisión de los puntajes.

AERA, APA y NCME (2014)

Segundo fundamento: Confiabilidad/Precisión

De acuerdo a los Estándares para el uso de pruebas educativas y psicológicas

De acuerdo a los estándares, el error o incertidumbre de una medición es considerado en términos de la confiabilidad de un instrumento.

CONFIABILIDAD COMO FUNDAMENTO:

La consistencia de los puntajes entre realizaciones de un procedimiento de medición, independientemente de cómo esta consistencia sea calculada o reportada.

Este fundamento apunta, en otras palabras, a la variación que se observaría si repitiéramos una medición en múltiples ocasiones.

Dos usos del concepto “Confiabilidad”

De acuerdo a los Estándares para el uso de pruebas educativas y psicológicas

- Los estándares distinguen entre dos usos de la palabra confiabilidad en la ciencias sociales:
 - El primer sentido, que recién revisamos, está asociado a la consistencia de los puntajes en mediciones repetidas es llamado “confiabilidad/precisión”.
 - El segundo sentido de confiabilidad se refiere a una forma particular de cuantificar esta consistencia de los puntajes, es decir, al coeficiente de confiabilidad en la teoría de puntaje verdadero.
- Es importante recordar que lo fundamental es el primero de estos sentidos, mientras que los coeficientes de confiabilidad son formas de estimar este fundamento.

Segundo fundamento: Confiabilidad/Precisión

De acuerdo a los Estándares para el uso de pruebas educativas y psicológicas

El principal tema en el cálculo de la confiabilidad/precisión es la dificultad de hacer mediciones repetidas en ciencias sociales.

Después de todo, no es razonable esperar que una persona responda la misma prueba múltiples veces, y que cada aplicación sea independiente de las anteriores.

La “confiabilidad/precisión” puede ser estimada de muchas formas distintas en medición en las ciencias sociales dependiendo entre otras cosas de (a) el diseño de recolección de respuestas y (b) del modelo de análisis estadístico que se esté utilizando para analizar las respuestas.

Distintos métodos y diseños de recolección de datos intentan solucionar el problema de la falta de múltiples mediciones repetidas e independientes de diferentes formas.

Tercer fundamento:
imparcialidad

Tercer fundamento: Imparcialidad

De acuerdo a los Estándares para el uso de pruebas educativas y psicológicas

La última versión de los estándares (publicada en el 2014) incluyó la imparcialidad como un tercer fundamento de la medición, además de los fundamentos tradicionales de validez y confiabilidad.

Una prueba que es imparcial de acuerdo a la definición de los estándares refleja el mismo constructo o constructos para todas quienes responden la prueba, y sus puntajes tienen el mismo significado para todos los individuos de la población de interés; una prueba ecuánime no da ventajas o desventajas a algunos individuos debido a características irrelevantes al constructo de interés.

AERA, APA y NCME (2014)

Imparcialidad como ausencia de sesgo

De acuerdo a los Estándares para el uso de pruebas educativas y psicológicas

El sesgo ocurre cuando una prueba favorece o perjudica a grupos de examinados. Por ejemplo: género, idioma, origen étnico, o estatus socioeconómico.

Los Estándares para el uso de pruebas educativas y psicológicas, hablan de sesgo como una amenaza fundamental para la imparcialidad en las pruebas.

Añaden dos conceptos importantes que han surgido en la literatura, para minimizar el sesgo.

- Accesibilidad: Todos quienes toman la prueba deben tener una oportunidad sin obstáculos de demostrar su habilidad en el constructo que se está midiendo.
- Diseño universal: Es un enfoque para el diseño de pruebas que busca maximizar la accesibilidad para todos los examinados destinados.

Imparcialidad/Sesgo


Enfatizando

Imparcialidad: Una evaluación o prueba ecuánime mide para todos los grupos de evaluados un atributo de interés, permitiendo interpretar los resultados con igual validez para todos ellos.

Sesgo: Los grupos no difieren en cuanto al estado real del atributo. Sin embargo, la prueba sugiere que sí lo hacen. En otras palabras, existe sesgo cuando para un mismo nivel del atributo que se está midiendo dos grupos o personas obtienen puntuaciones distintas.

Sesgo

Ejemplo



Tres fundamentos en los estándares

Validez, precisión y imparcialidad

La última versión de los Estándares (2014) incluye tres fundamentos de la medición:

VALIDEZ El grado en que evidencia y teoría respaldan las interpretaciones de puntajes de pruebas para sus usos propuestos.

PRECISIÓN/CONFIABILIDAD La consistencia de los puntajes entre realizaciones de un procedimiento de medición.

IMPARCIALIDAD La capacidad de responder a características individuales y a contextos de aplicación de las pruebas de tal forma que los puntajes de las pruebas produzcan interpretaciones válidas para los usos intencionados.

¿De qué depende que en una situación particular yo pueda afirmar (o no) que puedo medir un atributo?

¿Cuándo podemos decir que logramos medir un atributo que nos interesa?

1. Depende de la calidad del instrumento de medición que se usó para medir el atributo.

2. Depende de lo que pretendo hacer con los resultados de la medición.

3. Depende de lo que pretendo medir.

4. Depende de qué se esta entendiendo por “medir”.

“...we should at the very least not expect that psychological measurement be any easier [than physical measurement]”

- Maul, 2017